



As equações governantes da atmosfera

$$\frac{\partial(\bar{v})}{\partial t} + (\bar{u}) \frac{\partial(\bar{v})}{\partial x} + (\bar{v}) \frac{\partial(\bar{v})}{\partial y} + (\bar{w}) \frac{\partial(\bar{v})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial y} + 2\Omega\eta_3(\bar{v}) - \nu \frac{\partial^2(\bar{v})}{\partial x^2} - \nu \frac{\partial^2(\bar{v})}{\partial y^2} - \nu \frac{\partial^2(\bar{v})}{\partial z^2} = -\frac{\partial(\overline{u'v'})}{\partial x} - \frac{\partial(\overline{v'v'})}{\partial y} - \frac{\partial(\overline{w'v'})}{\partial z}$$

$$\frac{\partial(\bar{u})}{\partial t} + (\bar{u}) \frac{\partial(\bar{u})}{\partial x} + (\bar{v}) \frac{\partial(\bar{u})}{\partial y} + (\bar{w}) \frac{\partial(\bar{u})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial x} - 2\Omega\eta_3(\bar{u}) - \nu \frac{\partial^2(\bar{u})}{\partial x^2} - \nu \frac{\partial^2(\bar{u})}{\partial y^2} - \nu \frac{\partial^2(\bar{u})}{\partial z^2} = -\frac{\partial(\overline{u'u'})}{\partial x} - \frac{\partial(\overline{v'u'})}{\partial y} - \frac{\partial(\overline{w'u'})}{\partial z}$$

$$\frac{\partial(\bar{w})}{\partial t} + (\bar{u}) \frac{\partial(\bar{w})}{\partial x} + (\bar{v}) \frac{\partial(\bar{w})}{\partial y} + (\bar{w}) \frac{\partial(\bar{w})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial z} + g \frac{\bar{\rho}}{\rho_0} - \nu \frac{\partial^2(\bar{w})}{\partial x^2} - \nu \frac{\partial^2(\bar{w})}{\partial y^2} - \nu \frac{\partial^2(\bar{w})}{\partial z^2} = -\frac{\partial(\overline{u'w'})}{\partial x} - \frac{\partial(\overline{v'w'})}{\partial y} - \frac{\partial(\overline{w'w'})}{\partial z}$$

$$\frac{\partial(\bar{T})}{\partial t} + (\bar{u}) \frac{\partial(\bar{T})}{\partial x} + (\bar{v}) \frac{\partial(\bar{T})}{\partial y} + (\bar{w}) \frac{\partial(\bar{T})}{\partial z} - S_P \bar{\omega} = -\frac{\partial(\overline{u'T'})}{\partial x} - \frac{\partial(\overline{v'T'})}{\partial y} - \frac{\partial(\overline{w'T'})}{\partial z} + \frac{\bar{J}}{C_p}$$

$$\frac{\partial(\bar{q})}{\partial t} + (\bar{u}) \frac{\partial(\bar{q})}{\partial x} + (\bar{v}) \frac{\partial(\bar{q})}{\partial y} + (\bar{w}) \frac{\partial(\bar{q})}{\partial z} = -\frac{\partial(\overline{u'q'})}{\partial x} - \frac{\partial(\overline{v'q'})}{\partial y} - \frac{\partial(\overline{w'q'})}{\partial z} + \bar{S}$$

$$\begin{aligned} u_3 &= w \\ x_3 &= z \\ \nu \frac{\partial^2(\bar{u}_3)}{\partial x_3^2} &\cong 0 \end{aligned}$$



Lorenz demonstrou claramente que a **incerteza na condição inicial**, por menor que seja, levará a uma **incerteza na previsão** após determinado período de tempo, que é variável e depende do estado inicial da atmosfera.



Previsão Numérica de Tempo e Clima




Em 1963, Lorenz publicou seu trabalho seminal sobre o “**Fluxo determinístico não periódico**”, que viria a mudar profundamente o curso da previsão do tempo e do clima nas décadas seguintes e a colocar a **teoria do caos no centro da meteorologia**.

$$\frac{dX}{dt} = -\sigma X + \sigma Y + f$$

$$\frac{dY}{dt} = -XZ + \rho X - Y + f$$

$$\frac{dZ}{dt} = XY - \beta Z$$



$$\frac{Du_i}{Dt} = \frac{\partial u_i}{\partial t} + u_j \frac{\partial u_i}{\partial x_j} = -\frac{1}{\rho_0} \frac{\partial P}{\partial x_i} - \frac{\rho}{\rho_0} g \delta_{i3} - 2\Omega \varepsilon_{ijk} \eta_j u_k + \nu \left(\frac{\partial^2 u_i}{\partial x_j^2} \right)$$

De fato, pode-se dizer que **sua visão da atmosfera** (e, posteriormente, também dos oceanos) **como um sistema caótico** passou a influenciar nossa compreensão da **previsibilidade do tempo** e, posteriormente, do **clima**.



Previsão Numérica de Tempo e Clima



Lorenz foi capaz de demonstrar que, mesmo para um conjunto simples de equações não lineares (1.1), a evolução da solução poderia ser alterada por **perturbações extremamente pequenas nas condições iniciais**

$$\left. \begin{aligned} \frac{dX}{dt} &= -\sigma X + \sigma Y, \\ \frac{dY}{dt} &= -XZ + \rho X - Y \\ \frac{dZ}{dt} &= XY - \beta Z. \end{aligned} \right\}$$




Figura 1: Solução das equações do modelo de Lorenz (1) **ao longo de 1500 passos de tempo**, mostrando **um regime “quente”, com valores positivos** de x e y, e **um regime “frio”, com valores negativos** de x e y.

A solução normalmente permanece por várias voltas em **cada regime antes de mudar para** o outro regime.




Em outras palavras, além de determinado tempo de antecedência da previsão, deixa de existir uma única solução determinística e, portanto, **todas as previsões devem ser tratadas de forma probabilística.**



Previsão Numérica de Tempo e Clima



O **espaço de dimensão fracionária** ocupado pelas trajetórias das soluções dessas equações não lineares ficou conhecido como **atrator de Lorenz** (Figura 1).






Isso sugere que **sistemas não lineares**, como a atmosfera, podem apresentar **estruturas semelhantes a regimes** que, embora sejam completamente determinísticas, **estão sujeitas a “mudanças abruptas e aparentemente aleatórias.”**



Previsão Numérica de Tempo e Clima



Mas, ainda mais importante, o modelo de Lorenz também indica que a **previsibilidade de um sistema caótico depende do escoamento** (*flow-dependent*).








Previsão Numérica de Tempo e Clima



Alguns **padrões** ou **regimes meteorológicos** podem ser **altamente imprevisíveis**, outros podem apresentar um grau **substantial de previsibilidade**; em outras palavras, a própria previsibilidade é variável e também **previsível** (Figura 1).







Previsão Numérica de Tempo e Clima



Essa propriedade tem implicações fundamentais para a **previsão do tempo e do clima**, pois permite avaliar a **confiabilidade** e, conseqüentemente, o **grau de confiança na distribuição de probabilidade das previsões**.







Previsão Numérica de Tempo e Clima



Lorenz também analisou a **interação entre diferentes escalas de movimento** na determinação da **previsibilidade de um sistema**.



Os resultados mostraram que **erros na escala dos cúmulos** podem se propagar para a **escala sinótica** em apenas **dois dias** e atingir as **maiores escalas de movimento** em **duas semanas**.



A relevância desse estudo foi reconhecida no desenvolvimento de **abordagens estocásticas para representar a convecção de cúmulos e seus transportes de energia para escalas maiores**, bem como nos esforços recentes para **resolver esses processos multiescala** em simulações atmosféricas na **escala de resolução de sistemas de nuvens** (*cloud system-resolving scale*), de aproximadamente **1 km**.

A. Perturbação Estocástica das Tendências de Parametrização (SPPT)

Em vez de modificar a física interna da nuvem, o método **SPPT (Stochastic Perturbed Parameterization Tendencies)** multiplica a tendência líquida total de aquecimento (Q_1), umedecimento (Q_2) e momento (U, V) gerada pelo esquema de convecção por um padrão de ruído aleatório espacial e temporalmente correlacionado.

$$\left(\frac{\partial \psi}{\partial t} \right)_{total} = \left(\frac{\partial \psi}{\partial t} \right)_{resolvido} + (1 + e) \cdot \left(\frac{\partial \psi}{\partial t} \right)_{cumulus}$$

Onde e é um campo de ruído gaussiano que varia suavemente no espaço e no tempo para simular a incerteza do transporte convectivo.





Previsão Numérica de Tempo e Clima




Como a **teoria do caos** moldou nossa abordagem à **previsão numérica do tempo**, por que, apesar dos limites à previsibilidade atmosférica apontados por Lorenz, a **previsão sazonal** e até mesmo a **previsão decadal** são possíveis, e como a **incerteza deve ser abordada no contexto das mudanças climáticas**.

$$\left. \begin{aligned} \frac{dX}{dt} &= -\sigma X + \sigma Y + f, \\ \frac{dY}{dt} &= -XZ + \rho X - Y + f \\ \frac{dZ}{dt} &= XY - \beta Z. \end{aligned} \right\}$$



$$\begin{aligned} \frac{\partial(\bar{v})}{\partial t} + (\bar{u}) \frac{\partial(\bar{v})}{\partial x} + (\bar{v}) \frac{\partial(\bar{v})}{\partial y} + (\bar{w}) \frac{\partial(\bar{v})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial y} + 2\Omega \eta_3(\bar{v}) - v \frac{\partial^2(\bar{v})}{\partial x^2} - v \frac{\partial^2(\bar{v})}{\partial y^2} - v \frac{\partial^2(\bar{v})}{\partial z^2} &= -\frac{\partial(\bar{u}'\bar{v}')}{\partial x} - \frac{\partial(\bar{v}'\bar{v}')}{\partial y} - \frac{\partial(\bar{w}'\bar{v}')}{\partial z} \\ \frac{\partial(\bar{u})}{\partial t} + (\bar{u}) \frac{\partial(\bar{u})}{\partial x} + (\bar{v}) \frac{\partial(\bar{u})}{\partial y} + (\bar{w}) \frac{\partial(\bar{u})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial x} - 2\Omega \eta_3(\bar{u}) - v \frac{\partial^2(\bar{u})}{\partial x^2} - v \frac{\partial^2(\bar{u})}{\partial y^2} - v \frac{\partial^2(\bar{u})}{\partial z^2} &= -\frac{\partial(\bar{u}'\bar{u}')}{\partial x} - \frac{\partial(\bar{v}'\bar{u}')}{\partial y} - \frac{\partial(\bar{w}'\bar{u}')}{\partial z} \\ \frac{\partial(\bar{w})}{\partial t} + (\bar{u}) \frac{\partial(\bar{w})}{\partial x} + (\bar{v}) \frac{\partial(\bar{w})}{\partial y} + (\bar{w}) \frac{\partial(\bar{w})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial z} + g \frac{\bar{p}}{\rho_0} - v \frac{\partial^2(\bar{w})}{\partial x^2} - v \frac{\partial^2(\bar{w})}{\partial y^2} - v \frac{\partial^2(\bar{w})}{\partial z^2} &= -\frac{\partial(\bar{u}'\bar{w}')}{\partial x} - \frac{\partial(\bar{v}'\bar{w}')}{\partial y} - \frac{\partial(\bar{w}'\bar{w}')}{\partial z} \\ \frac{\partial(\bar{T})}{\partial t} + (\bar{u}) \frac{\partial(\bar{T})}{\partial x} + (\bar{v}) \frac{\partial(\bar{T})}{\partial y} + (\bar{w}) \frac{\partial(\bar{T})}{\partial z} - S_P \bar{\omega} &= -\frac{\partial(\bar{u}'\bar{T}')}{\partial x} - \frac{\partial(\bar{v}'\bar{T}')}{\partial y} - \frac{\partial(\bar{w}'\bar{T}')}{\partial z} + \frac{\bar{J}}{C_p} \\ \frac{\partial(\bar{q})}{\partial t} + (\bar{u}) \frac{\partial(\bar{q})}{\partial x} + (\bar{v}) \frac{\partial(\bar{q})}{\partial y} + (\bar{w}) \frac{\partial(\bar{q})}{\partial z} &= -\frac{\partial(\bar{u}'\bar{q}')}{\partial x} - \frac{\partial(\bar{v}'\bar{q}')}{\partial y} - \frac{\partial(\bar{w}'\bar{q}')}{\partial z} + \bar{S} \end{aligned}$$

$$\begin{aligned} u_3 &= w \\ x_3 &= z \\ v \frac{\partial^2(u_3)}{\partial x_3^2} &\approx 0 \end{aligned}$$





Lorenz demonstrou claramente que a incerteza na condição inicial, por menor que seja, levará a uma incerteza na previsão após determinado período de tempo, que é variável e depende do estado inicial da atmosfera.

$$ACC = \frac{\sum(f - c)(a - c)}{\sqrt{\sum(f - c)^2} \sqrt{\sum(a - c)^2}}$$


Quando aplicado a previsões :

- os valores de verificação podem ser as próprias análises, 'a', no momento da operação (*runtime*),
- as previsões podem ser previsões de para a data referida, 'f'.
- Isso permite calcular as anomalias em relação a uma climatologia, 'c'.



“2. Tratamento da incerteza na previsão do tempo”

Como consequência, a comunidade de **previsão numérica do tempo** começou a considerar o uso de **métodos probabilísticos para a previsão**, especialmente além do limite determinístico de aproximadamente **uma semana**, sugerido por Lorenz.



© 2020 European Centre for Medium-Range Weather Forecasts (ECMWF)
Source: www.ecmwf.int
License: CC BY 4.0 and ECMWF Terms of Use (<https://apps.ecmwf.int/datasets/sources/general/>)
Created at 2020-03-18T10:23:36.422Z



Figura 2. Tempo de antecedência necessário para que o coeficiente de correlação de anomalias (ACC) atinja múltiplos limiares nas previsões de altura geopotencial em 500 hPa do sistema de alta resolução (HRES).

Um ACC de 100% indica uma correlação perfeita entre a previsão e a análise de verificação.


A figura mostra o progresso contínuo da acurácia das previsões. Observe o “salto” ocorrido no início dos anos 2000, atribuído principalmente à assimilação de dados de satélite pelo método 4D-Var, que também contribuiu para a redução da diferença de desempenho entre os hemisférios Norte e Sul.

Em 2000, o limiar de 80% era atingido no 5º dia, enquanto, em 2020, era atingido no 7º dia, indicando uma melhoria na acurácia das previsões de aproximadamente 1 dia por década. (Simmons e Hollingsworth, 2002).





“2. Tratamento da incerteza na previsão do tempo”

As primeiras implementações de métodos probabilísticos na previsão numérica do tempo basearam-se na aplicação de **pequenas perturbações aleatórias às variáveis de estado da atmosfera** — temperatura, umidade, ventos e pressão — na **condição inicial analisada**.



11-member
ensemble
10km
Europe





PAULO TOSHIO KUBOTA



“2. Tratamento da incerteza na previsão do tempo”

Como a atmosfera é **não linear**, essas pequenas perturbações são posteriormente **amplificadas por processos caóticos**, fazendo com que cada previsão **se afaste progressivamente das demais** (Figura 2).




Mesmo ponto inicial, mas um parâmetro $\rho1 = 0.1$ e $\rho2 = 0.11$ diferente

$$\frac{dX}{dt} = -\sigma X + \sigma Y + f$$

$$\frac{dY}{dt} = -XZ + \rho X - Y + f$$

$$\frac{dZ}{dt} = XY - \beta Z$$

pequenas perturbações são posteriormente **amplificadas por processos caóticos**



atmosfera é **não linear**



$$\begin{aligned} \frac{\partial(\bar{v})}{\partial t} + (\bar{u})\frac{\partial(\bar{v})}{\partial x} + (\bar{v})\frac{\partial(\bar{v})}{\partial y} + (\bar{w})\frac{\partial(\bar{v})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial y} + 2\Omega\eta_3(\bar{v}) - \nu\frac{\partial^2(\bar{v})}{\partial x^2} - \nu\frac{\partial^2(\bar{v})}{\partial y^2} - \nu\frac{\partial^2(\bar{v})}{\partial z^2} &= -\frac{\partial(\bar{u}'v')}{\partial x} - \frac{\partial(\bar{v}'v')}{\partial y} - \frac{\partial(\bar{w}'v')}{\partial z} \\ \frac{\partial(\bar{u})}{\partial t} + (\bar{u})\frac{\partial(\bar{u})}{\partial x} + (\bar{v})\frac{\partial(\bar{u})}{\partial y} + (\bar{w})\frac{\partial(\bar{u})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial x} - 2\Omega\eta_3(\bar{u}) - \nu\frac{\partial^2(\bar{u})}{\partial x^2} - \nu\frac{\partial^2(\bar{u})}{\partial y^2} - \nu\frac{\partial^2(\bar{u})}{\partial z^2} &= -\frac{\partial(\bar{u}'u')}{\partial x} - \frac{\partial(\bar{v}'u')}{\partial y} - \frac{\partial(\bar{w}'u')}{\partial z} \\ \frac{\partial(\bar{w})}{\partial t} + (\bar{u})\frac{\partial(\bar{w})}{\partial x} + (\bar{v})\frac{\partial(\bar{w})}{\partial y} + (\bar{w})\frac{\partial(\bar{w})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial z} + g\frac{\bar{\rho}}{\rho_0} - \nu\frac{\partial^2(\bar{w})}{\partial x^2} - \nu\frac{\partial^2(\bar{w})}{\partial y^2} - \nu\frac{\partial^2(\bar{w})}{\partial z^2} &= -\frac{\partial(\bar{u}'w')}{\partial x} - \frac{\partial(\bar{v}'w')}{\partial y} - \frac{\partial(\bar{w}'w')}{\partial z} \\ \frac{\partial(\bar{T})}{\partial t} + (\bar{u})\frac{\partial(\bar{T})}{\partial x} + (\bar{v})\frac{\partial(\bar{T})}{\partial y} + (\bar{w})\frac{\partial(\bar{T})}{\partial z} - S_P\bar{\omega} &= -\frac{\partial(\bar{u}'T')}{\partial x} - \frac{\partial(\bar{v}'T')}{\partial y} - \frac{\partial(\bar{w}'T')}{\partial z} + \frac{\bar{J}}{C_p} \\ \frac{\partial(\bar{q})}{\partial t} + (\bar{u})\frac{\partial(\bar{q})}{\partial x} + (\bar{v})\frac{\partial(\bar{q})}{\partial y} + (\bar{w})\frac{\partial(\bar{q})}{\partial z} &= -\frac{\partial(\bar{u}'q')}{\partial x} - \frac{\partial(\bar{v}'q')}{\partial y} - \frac{\partial(\bar{w}'q')}{\partial z} + \bar{S} \end{aligned}$$

$$\begin{aligned} u_3 &= w \\ x_3 &= z \\ \nu\frac{\partial^2(u_3)}{\partial x_3^2} &\cong 0 \end{aligned}$$




“2. Tratamento da incerteza na previsão do tempo”

No canto superior esquerdo é apresentada a **depressão atmosférica profunda analisada**, com **ventos intensos e potencialmente danosos** em seu flanco sul.



No canto superior direito é apresentada a **previsão determinística**, enquanto os **50 painéis restantes** mostram outros resultados possíveis, obtidos a partir de **perturbações nas condições iniciais**.





Uma **parcela substancial do conjunto de previsões** indica o desenvolvimento de uma **depressão atmosférica profunda**.

Figura 3. Exemplo de uma **previsão probabilística de 66 horas** para os dias 15–16 de outubro de 1987.



“2. Tratamento da incerteza na previsão do tempo”

As vantagens da **previsão por conjuntos** tornaram-se rapidamente evidentes no caso da tempestade de outubro de 1987, quando Michael Fish, um meteorologista da **British Broadcasting Corporation (BBC)**, ficou famoso por ter dito: “.....**uma mulher telefonou para a BBC e disse que tinha ouvido que havia um furacão a caminho. Bem, se você está assistindo, não se preocupe, não há nenhum.**”



- Ele tinha acesso apenas a uma **previsão determinística**, que não fornecia nenhuma indicação sobre o que poderia acontecer.
- Se tivesse acesso a um **sistema totalmente probabilístico**, é bem possível que tivesse decidido emitir um **alerta de tempo severo** (Figura 3).



Desde então, a **previsão probabilística do tempo** tornou-se uma prática rotineira, e suas vantagens são hoje amplamente reconhecidas.



- Ela fornece uma **gama de soluções de previsão plausíveis**, permitindo ao meteorologista avaliar possíveis cenários, estimar os **riscos e as probabilidades** associados a esses cenários e avaliar o **nível de confiança na previsão final**.
- Do ponto de vista dos usuários, as **probabilidades da previsão** permitem que eles decidam qual nível de risco estão dispostos a assumir, dependendo de suas **vulnerabilidades**, e que tomem as medidas apropriadas com uma compreensão adequada das **incertezas envolvidas**.



“2. Tratamento da incerteza na previsão do tempo”

Entretanto, a eficácia dos métodos probabilísticos na previsão do tempo depende da confiabilidade do conjunto de previsões (ensemble). Nesse contexto, confiabilidade significa que as incertezas da previsão estão sendo representadas adequadamente.

As incertezas da previsão estão sendo representadas adequadamente?



$$\frac{\partial(\bar{v})}{\partial t} + (\bar{u})\frac{\partial(\bar{v})}{\partial x} + (\bar{v})\frac{\partial(\bar{v})}{\partial y} + (\bar{w})\frac{\partial(\bar{v})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial y} + 2\Omega\eta_3(\bar{v}) - v\frac{\partial^2(\bar{v})}{\partial x^2} - v\frac{\partial^2(\bar{v})}{\partial y^2} - v\frac{\partial^2(\bar{v})}{\partial z^2} = -\frac{\partial(\bar{u}'v')}{\partial x} - \frac{\partial(\bar{v}'v')}{\partial y} - \frac{\partial(\bar{w}'v')}{\partial z}$$

$$\frac{\partial(\bar{u})}{\partial t} + (\bar{u})\frac{\partial(\bar{u})}{\partial x} + (\bar{v})\frac{\partial(\bar{u})}{\partial y} + (\bar{w})\frac{\partial(\bar{u})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial x} - 2\Omega\eta_3(\bar{u}) - v\frac{\partial^2(\bar{u})}{\partial x^2} - v\frac{\partial^2(\bar{u})}{\partial y^2} - v\frac{\partial^2(\bar{u})}{\partial z^2} = -\frac{\partial(\bar{u}'u')}{\partial x} - \frac{\partial(\bar{v}'u')}{\partial y} - \frac{\partial(\bar{w}'u')}{\partial z}$$

$$\frac{\partial(\bar{w})}{\partial t} + (\bar{u})\frac{\partial(\bar{w})}{\partial x} + (\bar{v})\frac{\partial(\bar{w})}{\partial y} + (\bar{w})\frac{\partial(\bar{w})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial z} + g\frac{\bar{\rho}}{\rho_0} - v\frac{\partial^2(\bar{w})}{\partial x^2} - v\frac{\partial^2(\bar{w})}{\partial y^2} - v\frac{\partial^2(\bar{w})}{\partial z^2} = -\frac{\partial(\bar{u}'w')}{\partial x} - \frac{\partial(\bar{v}'w')}{\partial y} - \frac{\partial(\bar{w}'w')}{\partial z}$$

$$\frac{\partial(\bar{T})}{\partial t} + (\bar{u})\frac{\partial(\bar{T})}{\partial x} + (\bar{v})\frac{\partial(\bar{T})}{\partial y} + (\bar{w})\frac{\partial(\bar{T})}{\partial z} - S_P\bar{\omega} = -\frac{\partial(\bar{u}'T')}{\partial x} - \frac{\partial(\bar{v}'T')}{\partial y} - \frac{\partial(\bar{w}'T')}{\partial z} + \frac{\bar{J}}{c_p}$$

$$\frac{\partial(\bar{q})}{\partial t} + (\bar{u})\frac{\partial(\bar{q})}{\partial x} + (\bar{v})\frac{\partial(\bar{q})}{\partial y} + (\bar{w})\frac{\partial(\bar{q})}{\partial z} = -\frac{\partial(\bar{u}'q')}{\partial x} - \frac{\partial(\bar{v}'q')}{\partial y} - \frac{\partial(\bar{w}'q')}{\partial z} + \bar{S}$$

atmosfera é não linear

$$\begin{aligned} u_3 &= w \\ x_3 &= z \\ v\frac{\partial^2(\bar{u}_3)}{\partial x_3^2} &\cong 0 \end{aligned}$$




“2. Tratamento da incerteza na previsão do tempo”

As incertezas da previsão estão sendo representadas adequadamente?


perturbações aleatórias nas condições iniciais não apresentavam dispersão suficiente (*todos os possíveis valores da condição inicial*)

Global atmospheric data assimilation



Schär, ETH Zürich


11-member
ensemble
10km
Europe





“2. Tratamento da incerteza na previsão do tempo”

Tornou-se evidente, relativamente cedo, que os sistemas baseados apenas em **perturbações aleatórias nas condições iniciais** não apresentavam **dispersão suficiente** e que a gama de soluções não preenchia adequadamente o **espaço de fases dos estados possíveis da atmosfera real** ([3]; Figura 4).



NCEP (National Center for Environmental Prediction),
CMC (Meteorological Service of Canada)
ECM (European Centre for Medium-range Weather Forecasting).


Observe que o **erro da previsão** é baseado em uma **previsão de anomalias** e, portanto, **não inclui o viés sistemático do modelo**.

Figura 4. Estatísticas do erro quadrático médio (RMSE) da previsão da média do ensemble (linha contínua) e da **dispersão do ensemble (spread)** (linha pontilhada) no Hemisfério Norte, obtidas a partir de três sistemas de previsão por conjuntos



“2. Tratamento da incerteza na previsão do tempo”


O erro quadrático médio (RMSE) da anomalia da previsão da média do ensemble cresce mais rapidamente do que a **dispersão (*spread*)**. Isso indica que o ensemble é **subdispersivo (*under-dispersive*)** e, conseqüentemente, que a **previsão por ensemble é excessivamente confiante (*over-confident*)**.





“2. Tratamento da incerteza na previsão do tempo”

Essa falta de dispersão (spread) sugeria que as perturbações aplicadas às condições iniciais não eram ideais e não necessariamente capturavam os modos de crescimento mais rápido



capturavam os modos (ondas rápidas)

Foram realizados estudos consideráveis para **identificar esses modos** utilizando **técnicas de vetores singulares** (*singular vector techniques*), e foram obtidos avanços significativos no aumento da dispersão do ensemble..


No entanto, o ensemble continuava subdispersivo (under-dispersive), indicando que algum outro elemento estava faltando



“2. Tratamento da incerteza na previsão do tempo”




Numerosos estudos de modelos atmosféricos e comparações entre modelos (*intercomparisons*) mostraram que existe uma **grande divergência na qualidade das simulações**, **que pode estar relacionada à:**

1. formulação dinâmica do modelo



2. Mais provável às parametrização dos processos físicos associados ao aquecimento diabático:

- convecção de cúmulos,
- interações entre nuvens e radiação
- fluxos turbulentos na camada limite.



$$\frac{ds}{dt} \approx 0 \text{ processos adiabáticos secos}$$
$$\frac{dh}{dt} \approx 0 \text{ processos adiabáticos secos e úmidos}$$



“2. Tratamento da incerteza na previsão do tempo”

A abordagem usual consiste em definir as chamadas **formulações de grande escala** (*bulk formulae*), que procuram representar empiricamente as **propriedades estatísticas dos processos de subgrade** e como eles se relacionam com o **estado atmosférico (ou oceânico) de grande escala e resolvido pelo modelo**.

$$\frac{\partial(\bar{v})}{\partial t} + (\bar{u}) \frac{\partial(\bar{v})}{\partial x} + (\bar{v}) \frac{\partial(\bar{v})}{\partial y} + (\bar{w}) \frac{\partial(\bar{v})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial y} + 2\Omega\eta_3(\bar{v}) - \nu \frac{\partial^2(\bar{v})}{\partial x^2} - \nu \frac{\partial^2(\bar{v})}{\partial y^2} - \nu \frac{\partial^2(\bar{v})}{\partial z^2} = -\frac{\partial(\overline{u'v'})}{\partial x} - \frac{\partial(\overline{v'v'})}{\partial y} - \frac{\partial(\overline{w'v'})}{\partial z}$$

$$\frac{\partial(\bar{u})}{\partial t} + (\bar{u}) \frac{\partial(\bar{u})}{\partial x} + (\bar{v}) \frac{\partial(\bar{u})}{\partial y} + (\bar{w}) \frac{\partial(\bar{u})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial x} - 2\Omega\eta_3(\bar{u}) - \nu \frac{\partial^2(\bar{u})}{\partial x^2} - \nu \frac{\partial^2(\bar{u})}{\partial y^2} - \nu \frac{\partial^2(\bar{u})}{\partial z^2} = -\frac{\partial(\overline{u'u'})}{\partial x} - \frac{\partial(\overline{v'u'})}{\partial y} - \frac{\partial(\overline{w'u'})}{\partial z}$$

$$\frac{\partial(\bar{w})}{\partial t} + (\bar{u}) \frac{\partial(\bar{w})}{\partial x} + (\bar{v}) \frac{\partial(\bar{w})}{\partial y} + (\bar{w}) \frac{\partial(\bar{w})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial z} + g \frac{\bar{\rho}}{\rho_0} - \nu \frac{\partial^2(\bar{w})}{\partial x^2} - \nu \frac{\partial^2(\bar{w})}{\partial y^2} - \nu \frac{\partial^2(\bar{w})}{\partial z^2} = -\frac{\partial(\overline{u'w'})}{\partial x} - \frac{\partial(\overline{v'w'})}{\partial y} - \frac{\partial(\overline{w'w'})}{\partial z}$$

$$\frac{\partial(\bar{T})}{\partial t} + (\bar{u}) \frac{\partial(\bar{T})}{\partial x} + (\bar{v}) \frac{\partial(\bar{T})}{\partial y} + (\bar{w}) \frac{\partial(\bar{T})}{\partial z} - S_P \bar{\omega} = -\frac{\partial(\overline{u'T'})}{\partial x} - \frac{\partial(\overline{v'T'})}{\partial y} - \frac{\partial(\overline{w'T'})}{\partial z} + \frac{\bar{J}}{C_p}$$

$$\frac{\partial(\bar{q})}{\partial t} + (\bar{u}) \frac{\partial(\bar{q})}{\partial x} + (\bar{v}) \frac{\partial(\bar{q})}{\partial y} + (\bar{w}) \frac{\partial(\bar{q})}{\partial z} = -\frac{\partial(\overline{u'q'})}{\partial x} - \frac{\partial(\overline{v'q'})}{\partial y} - \frac{\partial(\overline{w'q'})}{\partial z} + \bar{S}$$


$$\begin{aligned} u_3 &= w \\ x_3 &= z \\ \nu \frac{\partial^2(\bar{u}_3)}{\partial x_3^2} &\cong 0 \end{aligned}$$

Tradicionalmente, tem sido adotada uma **abordagem determinística** para definir essas formulações de grande escala (*bulk formulae*) e seus **parâmetros de fechamento** (*closure parameters*), apesar da existência de **incertezas consideráveis** e de as observações indicarem uma **ampla gama de formulações e valores possíveis**.



“2. Tratamento da incerteza na previsão do tempo”

Portanto, fica claro que a **incerteza do próprio modelo**, juntamente com os **vieses sistemáticos** presentes na **simulação do modelo**, leva a uma **amostragem restrita do espaço de fases** das previsões e à **subdispersão do ensemble**.





“2. Tratamento da incerteza na previsão do tempo”



Estudos iniciais investigaram o papel da **incerteza do modelo**

- As perturbações aleatórias nos incrementos provenientes das parametrizações físicas, a cada passo de tempo (**Perturbação aleatória de parâmetros físico na mesma parametrização**).
- Outras abordagens utilizaram **variações aleatórias nos parâmetros de fechamento das parametrizações físicas** . **Uso de diferentes parametrizações de convecção**

Essas variações foram baseadas em uma gama de **estimativas observacionais e julgamento de especialistas**, e foram mantidas fixas ao longo de uma determinada simulação — a chamada **abordagem de parâmetros perturbados** (*perturbed parameter approach*).




“2. Tratamento da incerteza na previsão do tempo”



Algumas abordagens produziram algumas melhorias na **dispersão do ensemble**.

a abordagem de **parâmetros perturbados** mostrou-se mais valiosa no contexto do tratamento das incertezas nas projeções das mudanças climáticas, especialmente no que diz respeito à **sensibilidade climática**.





“2. Tratamento da incerteza na previsão do tempo”



A compreensão da atmosfera como um **sistema multiescala** e do papel das **interações entre escalas** na determinação da variabilidade do tempo e do clima desenvolveu-se significativamente, especialmente após o importante experimento **TOGA COARE**¹, realizado em 1992–1993.





Figure 6 Compensated zonal-wavenumber spectra of tropically-averaged (30°S to 30°N) horizontal kinetic energy. Horizontal kinetic energy spectra use the (a) total horizontal wind, (b) RW circulation, (c) IGW circulation. The spectra have been multiplied by a factor of $(k/360)^{5/3}$. Dashed black lines show reference slopes.





Figure 3 Tropically-averaged (30°S to 30°N) zonal-wavenumber spectra of 200 hPa pressure velocity. Dashed black lines show reference slopes.



“2. Tratamento da incerteza na previsão do tempo”


Como resultado, tornou-se cada vez mais claro que a **hipótese inerente aos esquemas tradicionais de parametrização**, segundo a qual **não existe acoplamento entre a dinâmica e a física nas escalas não resolvidas**, está atualmente sendo questionada.



não existe acoplamento
entre a dinâmica e a

física nas escalas não
resolvidas

?




$$\frac{\partial(\bar{T})}{\partial t} + (\bar{u}) \frac{\partial(\bar{T})}{\partial x} + (\bar{v}) \frac{\partial(\bar{T})}{\partial y} + (\bar{w}) \frac{\partial(\bar{T})}{\partial z} - S_p \bar{\omega} = - \frac{\partial(\overline{u'T'})}{\partial x} - \frac{\partial(\overline{v'T'})}{\partial y} - \frac{\partial(\overline{w'T'})}{\partial z} + \frac{\bar{J}}{c_p}$$

$$\frac{\partial(\bar{q})}{\partial t} + (\bar{u}) \frac{\partial(\bar{q})}{\partial x} + (\bar{v}) \frac{\partial(\bar{q})}{\partial y} + (\bar{w}) \frac{\partial(\bar{q})}{\partial z} = - \frac{\partial(\overline{u'q'})}{\partial x} - \frac{\partial(\overline{v'q'})}{\partial y} - \frac{\partial(\overline{w'q'})}{\partial z} + \bar{S}$$





“2. Tratamento da incerteza na previsão do tempo”

Isso é particularmente verdadeiro para a **convecção de cúmulos**, na qual os **cascades de energia para escalas maiores (*upscale energy cascades*)** são agora reconhecidos como uma parte fundamental da **convecção organizada**, especialmente nos trópicos (por exemplo, **linhas de instabilidade de mesoescala, ciclones tropicais e oscilações de Madden–Julian**; Figura 5).



A cascades de energia para escalas maiores (*upscale energy cascades*) são agora reconhecidos como uma parte fundamental da **convecção organizada**, especialmente nos trópicos








“2. Tratamento da incerteza na previsão do tempo”

Essencialmente, isso significa que os modelos, devido à sua resolução relativamente grosseira, deixam de representar alguns dos processos não lineares que são fundamentais para a atmosfera enquanto sistema caótico.

devido à sua resolução relativamente grosseira




deixam de representar alguns dos processos não lineares
(comprimento de onda pequeno)





“2. Tratamento da incerteza na previsão do tempo”

Atualmente, a **dispersão do ensemble** corresponde ao **erro médio do ensemble**, de modo que o sistema de previsão por conjuntos **já não apresenta subdispersão**.





“2. Tratamento da incerteza na previsão do tempo”

Finalmente, houve **avanços significativos nos sistemas de previsão por conjuntos para a previsão numérica do tempo:**

- de modo que tanto as **incertezas nas condições iniciais**
- quanto as **incertezas associadas à formulação do modelo**

são agora representadas.



“2. Tratamento da incerteza na previsão do tempo”



Os **métodos probabilísticos** são atualmente fundamentais para a previsão do tempo em todas as escalas, incluindo o **nowcasting** na escala de resolução de sistemas de nuvens, de aproximadamente **1–2 km**.


É provável que novos avanços sejam alcançados por meio da **redução contínua dos vieses do modelo**, decorrente do aprimoramento das parametrizações, e também por meio de abordagens mais inovadoras para definir as **incertezas nas condições iniciais**, utilizando a **assimilação de dados por conjuntos** (*ensemble data assimilation*) [13].

Ambos os fatores deverão contribuir para aumentar a **habilidade das previsões** (*forecast skill*) e produzir **estimativas mais confiáveis das probabilidades**, especialmente aquelas relacionadas a **eventos extremos**.



3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível? Em 1981, Charney e Shukla [14] escreveram:

“Foi demonstrado, por meio de **simulações numéricas**, que a variabilidade da **pressão média** e da **precipitação em julho**, decorrente de instabilidades do escoamento de curto período (**previsão de tempo**), ocorrendo na ausência de **anomalias nas condições de contorno (TSM constante)**,





pode explicar grande parte da variabilidade observada nas latitudes médias, mas não nas baixas latitudes.



3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?

Com base nas evidências disponíveis, sugere-se que **uma grande parte da variabilidade nas baixas latitudes** seja causada por **anomalias nas condições de contorno**, como a **temperatura da superfície do mar (TSM)**, o **albedo** e a **umidade do solo**



Essas variáveis, por possuírem **constantes de tempo mais longas**, são mais previsíveis do que as instabilidades do escoamento.”

E assim nasceu o conceito de previsão sazonal.



3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?

Em termos do modelo de Lorenz, o conceito de previsibilidade em prazo estendido associada a um forçamento externo, mas ainda dentro de um sistema caótico, foi analisado por Palmer [15].

$$\begin{aligned}\frac{dX}{dt} &= -\sigma X + \sigma Y + f \\ \frac{dY}{dt} &= -XZ + \rho X - Y + f \\ \frac{dZ}{dt} &= XY - \beta Z\end{aligned}$$

$$\begin{aligned}\frac{\partial(\bar{v})}{\partial t} + (\bar{u})\frac{\partial(\bar{v})}{\partial x} + (\bar{v})\frac{\partial(\bar{v})}{\partial y} + (\bar{w})\frac{\partial(\bar{v})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial y} + 2\Omega\eta_3(\bar{v}) - v\frac{\partial^2(\bar{v})}{\partial x^2} - v\frac{\partial^2(\bar{v})}{\partial y^2} - v\frac{\partial^2(\bar{v})}{\partial z^2} &= -\frac{\partial(\bar{u}'v')}{\partial x} - \frac{\partial(\bar{v}'v')}{\partial y} - \frac{\partial(\bar{w}'v')}{\partial z} \\ \frac{\partial(\bar{u})}{\partial t} + (\bar{u})\frac{\partial(\bar{u})}{\partial x} + (\bar{v})\frac{\partial(\bar{u})}{\partial y} + (\bar{w})\frac{\partial(\bar{u})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial x} - 2\Omega\eta_3(\bar{u}) - v\frac{\partial^2(\bar{u})}{\partial x^2} - v\frac{\partial^2(\bar{u})}{\partial y^2} - v\frac{\partial^2(\bar{u})}{\partial z^2} &= -\frac{\partial(\bar{u}'u')}{\partial x} - \frac{\partial(\bar{v}'u')}{\partial y} - \frac{\partial(\bar{w}'u')}{\partial z} \\ \frac{\partial(\bar{w})}{\partial t} + (\bar{u})\frac{\partial(\bar{w})}{\partial x} + (\bar{v})\frac{\partial(\bar{w})}{\partial y} + (\bar{w})\frac{\partial(\bar{w})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial z} + g\frac{\bar{p}}{\rho_0} - v\frac{\partial^2(\bar{w})}{\partial x^2} - v\frac{\partial^2(\bar{w})}{\partial y^2} - v\frac{\partial^2(\bar{w})}{\partial z^2} &= -\frac{\partial(\bar{u}'w')}{\partial x} - \frac{\partial(\bar{v}'w')}{\partial y} - \frac{\partial(\bar{w}'w')}{\partial z} \\ \frac{\partial(\bar{T})}{\partial t} + (\bar{u})\frac{\partial(\bar{T})}{\partial x} + (\bar{v})\frac{\partial(\bar{T})}{\partial y} + (\bar{w})\frac{\partial(\bar{T})}{\partial z} - S_P\bar{\omega} &= -\frac{\partial(\bar{u}'T')}{\partial x} - \frac{\partial(\bar{v}'T')}{\partial y} - \frac{\partial(\bar{w}'T')}{\partial z} + \frac{\bar{J}}{C_p} \\ \frac{\partial(\bar{q})}{\partial t} + (\bar{u})\frac{\partial(\bar{q})}{\partial x} + (\bar{v})\frac{\partial(\bar{q})}{\partial y} + (\bar{w})\frac{\partial(\bar{q})}{\partial z} &= -\frac{\partial(\bar{u}'q')}{\partial x} - \frac{\partial(\bar{v}'q')}{\partial y} - \frac{\partial(\bar{w}'q')}{\partial z} + \bar{S}\end{aligned}$$

$$\begin{aligned}u_3 &= w \\ x_3 &= z \\ v\frac{\partial^2(u_3)}{\partial x_3^2} &\cong 0\end{aligned}$$

Ele demonstrou que, **se um forçamento, (f)**, for **incluído nas equações de Lorenz**, o tempo de permanência nos regimes do atrator de Lorenz pode mudar de uma maneira previsível;

em outras palavras, a resposta climática é previsível, mesmo quando o forçamento é fraco.



“Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?


Utilizando o modelo de Lorenz e variando a intensidade do forçamento, também é possível demonstrar que o número e os padrões espaciais dos regimes permanecem os mesmos, mas sua frequência de ocorrência é alterada (Figura 6).

Figura 6. Exemplos das séries temporais da variável (X) no modelo de Lorenz, evoluindo sobre o atrator de Lorenz para:

(a) ausência de forçamento externo

(b) forçamento externo intenso.

As mudanças na probabilidade de ocorrência **do regime superior e do regime inferior** são **afetadas de maneira previsível pelo ‘forçamento’ imposto.**




Isso corresponde essencialmente ao que Charney e Shukla haviam conjecturado, pelo menos para a atmosfera tropical, onde o El Niño, em particular, afeta os regimes do tempo tropical e, de fato, também os regimes do tempo em latitudes médias, especialmente sobre o oeste dos Estados Unidos.





3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?

Por outro lado, é possível que, para forçamentos mais intensos, o número e o padrão dos regimes possam se alterar.



Uma questão importante é saber se a mudança climática antropogênica decorrente do aumento dos gases de efeito estufa constitui um forçamento suficientemente intenso para levar ao surgimento de uma população de novos regimes.







3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?



No contexto da **previsão sazonal a decadal**, a **previsibilidade do sistema reside principalmente nos oceanos**, onde **a maior capacidade térmica e as escalas de tempo dinâmicas** muito mais longas para o ajuste **conferem memória ao sistema acoplado oceano-atmosfera**, que excede em várias ordens de magnitude aquela da atmosfera isoladamente.



Uma ilustração simplificada da “correia transportadora” global de correntes oceânicas que transportam calor ao redor da Terra. Vermelho mostra correntes de superfície e azul mostra correntes profundas. As águas profundas se formam onde a superfície do mar é mais densa. A cor de fundo mostra a densidade da superfície do mar. Crédito: NASA/ Goddard Space Flight Center Estúdio de Visualização Científica (Fundo)




O **oceano, assim como a atmosfera**, é um **sistema caótico e não linear** e, portanto, uma abordagem por **conjuntos (ensemble) para a previsão sazonal a decadal** é também **fundamental para a previsão nessas escalas de tempo**




3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?




Os desenvolvimentos mais recentes na **previsão sazonal a decadal envolvem modelos totalmente acoplados do oceano e da atmosfera**, nos quais ambos os componentes precisam ser **inicializados a partir de observações**, de modo a **representar o estado atual do sistema climático**.



cobertura observacional muito deficiente



incertezas nas condições iniciais







3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?

Assim como na previsão do tempo,

os sistemas de previsão por conjuntos (ensemble) normalmente consideram tanto a incerteza nas condições iniciais quanto a incerteza do modelo, utilizando física estocástica.






3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?



Por exemplo, o **El Niño** produz efeitos previsíveis nos trópicos em escala global e sobre a América do Norte e a América do Sul, e determinadas fases do El Niño são mais previsíveis do que outras (Figura 7).



- (a) O **início do El Niño é difícil** de prever devido ao forçamento estocástico proveniente da atmosfera, por exemplo, eventos de ventos de oeste.
- (b) O **declínio de um evento de El Niño é mais previsível** devido ao papel da dinâmica oceânica equatorial.


Figura 7. Duas previsões sazonais por conjuntos (**ensemble**) contrastantes do Centro Europeu de Previsões Meteorológicas de Médio Prazo (ECMWF) para a evolução do El Niño.



3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?



Entretanto, diferentemente da previsão do tempo, os vieses específicos do modelo crescem mais intensamente em um sistema totalmente acoplado, a ponto de a distribuição dos resultados prováveis nas previsões sazonais a decadais poder não representar a distribuição observada (Figura 8a) e, portanto, as previsões podem não ser confiáveis.



(a) o impacto dos vieses do modelo

b) um clima em mudança.




A **incerteza nas previsões** do modelo resulta tanto da incerteza nas condições iniciais quanto da incerteza do modelo.

Figura 8. Esquema de um sistema de previsão por conjuntos (ensemble) em escalas de tempo sazonais a decadais, baseado na Figura 1.



3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?

Por isso, **é essencial que a confiabilidade das previsões** seja avaliada utilizando **grandes conjuntos de retrospectivas do modelo** (model *hindcasts*).



The importance of initial and boundary conditions with forecast lead time


Isso permite calibrar as probabilidades das previsões com base no desempenho passado e corrigir o viés do modelo.



3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?



Entretanto, esses **métodos de correção empírica (vies) são essencialmente lineares**, enquanto sabemos que o sistema real é altamente não linear.



Como demonstrado por Turner et al. [16], existe intrinsecamente uma habilidade preditiva (predictive skill) muito maior quando se conseguem aprimoramentos na formulação do modelo que reduzam esses vieses, em vez de simplesmente corrigi-los posteriormente.



3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?

Também ocorre que os vieses específicos do modelo, tanto no estado médio quanto na variabilidade interna, levam à subdispersão do ensemble.

$$\frac{dX}{dt} = -\sigma X + \sigma Y + f$$

$$\frac{dY}{dt} = -XZ + \rho X - Y + f$$

$$\frac{dZ}{dt} = XY - \beta Z$$

$$\frac{\partial(\bar{v})}{\partial t} + (\bar{u})\frac{\partial(\bar{v})}{\partial x} + (\bar{v})\frac{\partial(\bar{v})}{\partial y} + (\bar{w})\frac{\partial(\bar{v})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial y} + 2\Omega\eta_3(\bar{v}) - v\frac{\partial^2(\bar{v})}{\partial x^2} - v\frac{\partial^2(\bar{v})}{\partial y^2} - v\frac{\partial^2(\bar{v})}{\partial z^2} = -\frac{\partial(\bar{u}'v')}{\partial x} - \frac{\partial(\bar{v}'v')}{\partial y} - \frac{\partial(\bar{w}'v')}{\partial z}$$

$$\frac{\partial(\bar{u})}{\partial t} + (\bar{u})\frac{\partial(\bar{u})}{\partial x} + (\bar{v})\frac{\partial(\bar{u})}{\partial y} + (\bar{w})\frac{\partial(\bar{u})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial x} - 2\Omega\eta_3(\bar{u}) - v\frac{\partial^2(\bar{u})}{\partial x^2} - v\frac{\partial^2(\bar{u})}{\partial y^2} - v\frac{\partial^2(\bar{u})}{\partial z^2} = -\frac{\partial(\bar{u}'u')}{\partial x} - \frac{\partial(\bar{v}'u')}{\partial y} - \frac{\partial(\bar{w}'u')}{\partial z}$$

$$\frac{\partial(\bar{w})}{\partial t} + (\bar{u})\frac{\partial(\bar{w})}{\partial x} + (\bar{v})\frac{\partial(\bar{w})}{\partial y} + (\bar{w})\frac{\partial(\bar{w})}{\partial z} + \frac{1}{\rho_0}\frac{\partial(\bar{P})}{\partial z} + g\frac{\bar{\rho}}{\rho_0} - v\frac{\partial^2(\bar{w})}{\partial x^2} - v\frac{\partial^2(\bar{w})}{\partial y^2} - v\frac{\partial^2(\bar{w})}{\partial z^2} = -\frac{\partial(\bar{u}'w')}{\partial x} - \frac{\partial(\bar{v}'w')}{\partial y} - \frac{\partial(\bar{w}'w')}{\partial z}$$

$$\frac{\partial(\bar{T})}{\partial t} + (\bar{u})\frac{\partial(\bar{T})}{\partial x} + (\bar{v})\frac{\partial(\bar{T})}{\partial y} + (\bar{w})\frac{\partial(\bar{T})}{\partial z} - S_P\bar{\omega} = -\frac{\partial(\bar{u}'T')}{\partial x} - \frac{\partial(\bar{v}'T')}{\partial y} - \frac{\partial(\bar{w}'T')}{\partial z} + \frac{\bar{J}}{C_p}$$

$$\frac{\partial(\bar{q})}{\partial t} + (\bar{u})\frac{\partial(\bar{q})}{\partial x} + (\bar{v})\frac{\partial(\bar{q})}{\partial y} + (\bar{w})\frac{\partial(\bar{q})}{\partial z} = -\frac{\partial(\bar{u}'q')}{\partial x} - \frac{\partial(\bar{v}'q')}{\partial y} - \frac{\partial(\bar{w}'q')}{\partial z} + \bar{S}$$

$$u_3 = w \\ x_3 = z \\ v\frac{\partial^2(u_3)}{\partial x_3^2} \cong 0$$

Isso levou ao uso de ensembles multimodelo (multi-model ensembles), nos **quais os diferentes vieses específicos de cada modelo permitem que o espaço de fases das previsões seja amostrado de forma mais completa**, proporcionando, conseqüentemente, maior confiabilidade ao sistema de previsão por conjuntos [17].



3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?

Entretanto, **é preciso reconhecer que, em comparação com a abordagem baseada em parametrizações estocásticas, o ensemble multimodelo é um conceito bastante *ad hoc* e, como será discutido a seguir, depende dos modelos** que, por acaso, estejam disponíveis no momento da realização das previsões.

$$\frac{\partial(\bar{v})}{\partial t} + (\bar{u}) \frac{\partial(\bar{v})}{\partial x} + (\bar{v}) \frac{\partial(\bar{v})}{\partial y} + (\bar{w}) \frac{\partial(\bar{v})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial y} + 2\Omega\eta_3(\bar{v}) - v \frac{\partial^2(\bar{v})}{\partial x^2} - v \frac{\partial^2(\bar{v})}{\partial y^2} - v \frac{\partial^2(\bar{v})}{\partial z^2} = -\frac{\partial(\bar{u}'v')}{\partial x} - \frac{\partial(\bar{v}'v')}{\partial y} - \frac{\partial(\bar{w}'v')}{\partial z}$$

$$\frac{\partial(\bar{u})}{\partial t} + (\bar{u}) \frac{\partial(\bar{u})}{\partial x} + (\bar{v}) \frac{\partial(\bar{u})}{\partial y} + (\bar{w}) \frac{\partial(\bar{u})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial x} - 2\Omega\eta_3(\bar{u}) - v \frac{\partial^2(\bar{u})}{\partial x^2} - v \frac{\partial^2(\bar{u})}{\partial y^2} - v \frac{\partial^2(\bar{u})}{\partial z^2} = -\frac{\partial(\bar{u}'u')}{\partial x} - \frac{\partial(\bar{v}'u')}{\partial y} - \frac{\partial(\bar{w}'u')}{\partial z}$$

$$\frac{\partial(\bar{w})}{\partial t} + (\bar{u}) \frac{\partial(\bar{w})}{\partial x} + (\bar{v}) \frac{\partial(\bar{w})}{\partial y} + (\bar{w}) \frac{\partial(\bar{w})}{\partial z} + \frac{1}{\rho_0} \frac{\partial(\bar{P})}{\partial z} + g \frac{\bar{\rho}}{\rho_0} - v \frac{\partial^2(\bar{w})}{\partial x^2} - v \frac{\partial^2(\bar{w})}{\partial y^2} - v \frac{\partial^2(\bar{w})}{\partial z^2} = -\frac{\partial(\bar{u}'w')}{\partial x} - \frac{\partial(\bar{v}'w')}{\partial y} - \frac{\partial(\bar{w}'w')}{\partial z}$$

$$\frac{\partial(\bar{T})}{\partial t} + (\bar{u}) \frac{\partial(\bar{T})}{\partial x} + (\bar{v}) \frac{\partial(\bar{T})}{\partial y} + (\bar{w}) \frac{\partial(\bar{T})}{\partial z} - S_P \bar{\omega} = -\frac{\partial(\bar{u}'T')}{\partial x} - \frac{\partial(\bar{v}'T')}{\partial y} - \frac{\partial(\bar{w}'T')}{\partial z} + \frac{\bar{J}}{c_p}$$

$$\frac{\partial(\bar{q})}{\partial t} + (\bar{u}) \frac{\partial(\bar{q})}{\partial x} + (\bar{v}) \frac{\partial(\bar{q})}{\partial y} + (\bar{w}) \frac{\partial(\bar{q})}{\partial z} = -\frac{\partial(\bar{u}'q')}{\partial x} - \frac{\partial(\bar{v}'q')}{\partial y} - \frac{\partial(\bar{w}'q')}{\partial z} + \bar{S}$$

$$\begin{aligned} u_3 &= w \\ x_3 &= z \\ v \frac{\partial^2(\bar{u}_3)}{\partial x_3^2} &\cong 0 \end{aligned}$$



3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?



O processo de calibração das previsões utilizando retrospectivas (**hindcasts**) apresenta, contudo, alguns desafios importantes.

Primeiramente, a base observacional melhorou substancialmente nas últimas décadas, especialmente para os oceanos e, portanto, a habilidade das previsões também pode melhorar simplesmente devido à melhor definição das condições iniciais.

Em segundo lugar, o processo de calibração pressupõe que o clima atual seja estacionário, mas existem evidências claras de que o clima está mudando (ver os Relatório de Avaliação do Painel Intergovernamental sobre Mudanças Climáticas — IPCC), especialmente em relação à temperatura; mesmo no Reino Unido, o sinal dessa mudança começa a emergir nas últimas tres décadas.

Isso significa, por exemplo, que a previsão sazonal do Reino Unido para o inverno de 2009–2010 **indicava uma probabilidade de 20% de ocorrência de um inverno frio quando calibrada com base nos últimos 40 anos, mas uma probabilidade muito maior (superior a 40%) se o sistema tivesse sido calibrado com base nos últimos 10 anos.**



3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?



Embora tanto a **natureza limitada da base observacional** quanto um clima em mudança apresentem alguns problemas para a previsão sazonal, para a previsão decadal **esses fatores constituem desafios extremamente complexos.**

Existe previsibilidade em escala decadal no sistema climático por meio de fenômenos como:

a oscilação multidecadal do Atlântico (Atlantic Multidecadal Oscillation — AMO)

a oscilação decadal do Pacífico (Pacific Decadal Oscillation — PDO) [18,19],

nossa **compreensão desses fenômenos ainda é limitada**, em grande parte devido à escassez de observações oceânicas.



3. “Previsibilidade em meio ao caos”: por que a previsão sazonal e decadal é possível?



Entretanto, a previsão decadal efetivamente estabelece uma ponte entre a **previsão sazonal e as projeções de mudanças climáticas**.

Ela, portanto, a previsão decadal desempenha um papel importante na compreensão da sensibilidade climática, pois uma parcela significativa da previsibilidade em escalas de tempo decadais decorre das mudanças nos níveis de concentração dos gases de efeito estufa.

Assim, embora a **previsão sazonal operacional** esteja atualmente bem estabelecida, ainda serão **necessários alguns anos até que a previsão decadal possa ser utilizada com confiança**. Seu potencial, contudo, é enorme [20].



4. Incerteza nas projeções das mudanças climáticas



A incerteza nas projeções das mudanças climáticas apresenta alguns desafios diferentes daqueles associados à **incerteza na previsão do tempo ou na previsão sazonal**.

A influência das condições iniciais do oceano é pequena **após aproximadamente uma década** e, desconsiderando as incertezas nos cenários de emissões, **a principal fonte de incerteza passa então a ser a formulação dos modelos** Figura 9), relacionada particularmente à sensibilidade do sistema climático ao forçamento provocado pelos gases de efeito estufa.




Figura 9.

- (a) Resposta da temperatura média anual da superfície e
- (b) da precipitação

Figura 9. Respostas às emissões do cenário A1B do *Special Report on Emission Scenarios*, em 21 modelos climáticos que contribuíram para o Quarto Relatório de Avaliação do IPCC. A linha preta contínua representa a média do ensemble multimodelo.



4. Incerteza nas projeções das mudanças climáticas



A **incerteza nas projeções das mudanças climáticas** tem sido tradicionalmente avaliada utilizando **ensembles multimodelo do tipo apresentado na Figura 9**, essencialmente um “**ensemble de oportunidade**” (*ensemble of opportunity*)

- A principal vantagem dessa abordagem é que **cada modelo difere substancialmente** em suas hipóteses estruturais e cada um deles foi amplamente testado
- A **credibilidade de sua projeção** é obtida a partir da avaliação de **sua capacidade de simular o clima atual** em comparação com uma **ampla variedade de observações**.



4. Incerteza nas projeções das mudanças climáticas

Entretanto, essa abordagem também apresenta **limitações significativas**.

O ensemble não foi projetado para testar toda a gama de resultados possíveis.

Seu **tamanho é muito pequeno** → tipicamente de 10 a 20 membros → limitações significativas → para **fornecer estimativas robustas das mudanças mais prováveis e das incertezas associadas** e, portanto, é **difícil utilizá-lo em avaliações de risco**.



4. Incerteza nas projeções das mudanças climáticas



Como já observado, **grande parte da incerteza nas projeções apresentadas na Figura 9 decorre da representação dos processos físicos de subgrade no modelo, particularmente dos efeitos de retroalimentação entre nuvens e radiação**.




Figura 9.



- (a) Resposta da temperatura média anual da superfície e
- (b) da precipitação

Mais recentemente, **demonstrou-se que a resposta do ciclo do carbono ao aquecimento global** também é importante, mas esse processo ainda não é incluído de forma universal nas projeções.



4. Incerteza nas projeções das mudanças climáticas

Uma exploração mais abrangente, sistemática e quantitativa das fontes de incerteza dos modelos, utilizando grandes ensembles de parâmetros perturbados, foi realizada por Murphy et al. e Stainforth et al., com o objetivo de investigar uma gama mais ampla de possíveis sensibilidades climáticas globais futuras.






investigar uma gama mais ampla de possíveis sensibilidades climáticas globais futuras.

grandes ensembles de parâmetros perturbados



4. Incerteza nas projeções das mudanças climáticas

O conceito consiste em utilizar uma estrutura baseada em um único modelo para **perturbar sistematicamente parâmetros do modelo** que apresentam baixa restrição observacional, relacionados a **processos físicos e biogeoquímicos fundamentais** — incluindo o ciclo do carbono — dentro de intervalos especificados por especialistas.




grandes ensembles de parâmetros perturbados



4. Incerteza nas projeções das mudanças climáticas



Assim como na **abordagem multimodelo**, ainda **é necessário testar cada versão do modelo em relação ao clima atual antes** de permitir sua inclusão no ensemble de parâmetros perturbados.






abordagem multimodelo

Uma **desvantagem evidente dessa abordagem** é que **ela não amostra a incerteza estrutural dos modelos, como resolução, estruturas de grade e métodos numéricos**, pois **depende de uma estrutura baseada em um único modelo**.



4. Incerteza nas projeções das mudanças climáticas

Como os tamanhos dos ensembles na abordagem de parâmetros perturbados chegam a centenas ou até mesmo a muitos milhares de membros, o resultado é uma **distribuição de probabilidade das mudanças climáticas**, em vez de uma faixa de incerteza obtida a partir de um conjunto limitado de resultados igualmente possíveis, como apresentado na Figura 9.



Isso **significa que a tomada de decisão sobre adaptação**, por exemplo, pode agora utilizar uma abordagem baseada em risco, fundamentada na probabilidade de ocorrência de um determinado resultado.



4. Incerteza nas projeções das mudanças climáticas

Esse conceito foi posteriormente ampliado por Murphy et al.] para *as mudanças climáticas regionais na Europa*, com base no *downscaling* por modelos regionais a partir do ensemble global de parâmetros perturbados. O estudo também incorporou uma estrutura estatística bayesiana, desenvolvida para apoiar a geração de probabilidades condicionadas a uma ampla variedade de métricas observacionais.



4. Incerteza nas projeções das mudanças climáticas

Isso permitiu, essencialmente, **que os membros do ensemble recebessem diferentes pesos de acordo com sua capacidade de reproduzir o clima atual**. A estrutura bayesiana também **considera uma incerteza estrutural adicional dos modelos**, utilizando o ensemble multimodelo.